

apprentissage automatique préservant la  
confidentialité basé sur le chiffrement  
homomorphique

Serigne Saliou Gueye

April 15, 2021

---

# REMERCIEMENTS

Acknowledgement goes here

---

## RESUMÉ

---

## INTRODUCTION GÉNÉRALE

---

## ABSTRACT

---

## CONTENTS

<b>I</b>	<b>Contexte et introduction</b>	<b>3</b>
<b>1</b>	<b>Notion Préliminaires de la cryptographie</b>	<b>3</b>
1.1	Introduction . . . . .	3
1.2	Sécurité inconditionnelle . . . . .	4
1.2.1	Notion de sécurité parfaite . . . . .	4
1.2.2	principe de Kerckhoff . . . . .	5
1.2.3	Principe de Shannon . . . . .	5

1.2.4	Théorème du secret parfait . . . . .	5
1.3	définition de sécurité pour la cryptographie à clé privée . . . . .	9
1.3.1	sécurité EAV . . . . .	9
1.3.2	Attaque par texte clair choisi (Chosen plaintext Attack CPA) . . . . .	10
1.3.3	Attaque à chiffré choisi (Chosen Cipher text Attack)(CCA) . . . . .	11
1.4	Cryptographie à clé publique . . . . .	13
1.4.1	Fonction à sens unique . . . . .	13
1.4.2	Fonction de hashage . . . . .	13
1.4.3	Modélisation du chiffrement à clés publique . . . . .	14
<b>2</b>	<b>Le chiffrement homomorphe</b>	<b>15</b>
2.1	Introduction . . . . .	15
2.2	Concept du chiffrement homomorphe . . . . .	15
2.2.1	Modélisation du chiffrement homomorphe . . . . .	15
2.3	Sécurité des cryptosystèmes homomorphe . . . . .	18
2.3.1	La Malléabilité . . . . .	18
<b>3</b>	<b>Notion Préliminaires de machine learning</b>	<b>20</b>
3.1	Introduction . . . . .	20
3.2	Classification binaire . . . . .	21
3.3	Classification naïve bayésienne . . . . .	24
3.4	Regression linéaire . . . . .	25
3.5	Annalyse des composantes principales (ACP) . . . . .	26

---

---

# **PART I**

---

## **CONTEXTE ET INTRODUCTION**

---

---

### **CHAPTER 1**

---

## **NOTION PRÉLIMINAIRES DE LA CRYPTOGRAPHIE**

Avant de passer à la définition du chiffrement homomorphe, nous allons revenir sur quelques notions cryptographiques à savoir les différents systèmes cryptographique (systèmes à clés secrètes et à clés privés) et aussi parler de la sécurité prouvée en cryptographie. Pour des traitements beaucoup plus approfondis de ces concepts nous renvoyons le lecteur sur [4]

### **1.1 Introduction**

La cryptographie est une discipline des maths incluant des principes et méthodes permettant de garantir les services de sécurité de l'information .Sa principale mission est de garantir la sécurité des communications c'est-à-dire de permettre à des entités qui ne se font pas confiance en général de communiquer en toute sécurité en présence de potentiels adversaires (susceptibles entre autres d'accéder à des secrets en violant la confidentialité, d'intercepter et de modifier les informations échangées ou d'usurper des identités lors d'une communication).

La cryptographie ne prend en charge que les 4 premiers sur les 5 services de sécurité fondamentaux que sont la Confidentialité, l'intégrité, l'authentification, la Non Répudiation et la Disponibilité.Elle est composée des systèmes à clé secrète

et des systèmes à clés publiques.

Dans un système à clés secrètes les entités se partagent la même clé pour le chiffrement et le déchiffrement (on parle de cryptographie symétrique)

Dans le cas du système à clé publique, on utilise deux clés dont l'une soit  $k'$  est difficile à déduire de l'autre soit  $k$  (on parle aussi de cryptographie asymétrique). La clé  $k$  est appelée clé publique et est utilisée pour le chiffrement ou la vérification de signature selon le système ; la clé  $k'$  est appelée clé privée et est utilisée pour le déchiffrement ou la signature selon le système.

Les algorithmes de chiffréments et les protocoles cryptographique sont impliqués dans une variété d'applications critiques: : les banques en ligne, le vote électronique, la vente aux enchères électroniques... En tant que tels, leurs sécurités doivent donc être formellement vérifiées et prouvées

## 1.2 Sécurité inconditionnelle

### 1.2.1 Notion de sécurité parfaite

Un cryptosystème est parfois définis par trois algorithmes :Algorithme de génération des clés ,de chiffrement et de déchiffrement ainsi qu'une specification d'un espace de message  $M$  avec  $\#M > 1$

L'algorithme de génération des clés que nous notons GEN est un algorithme probabiliste qui produit une clé  $k$  choisit selon une certaine distribution. Nous désignons par  $K$  l'espace des clés c'est à dire l'ensemble de toutes les clés possibles qui peuvent être sortis par GEN

L'algorithme de chiffrement que nous allons noté par ENC prend en entrée une clé  $\kappa \in K$  et un message  $m \in M$  produit un chiffré  $c$  .Nous considérons que l'algorithme de chiffrement est probabiliste donc  $ENC(k,m)$  peut alors générer des chiffrés différents lorsque le même message est utilisé.On note  $c \mapsto ENC_{\kappa}(m)$ .On note  $C$  l'ensemble de tous les chiffrés possibles

L'algorithme de déchiffrement noté par DEC prend en entrée une clé  $\kappa$  et un chiffré  $c$  et produit le message initial  $m$ . Contrairement à ENC l'algorithme de déchiffrement est déterministe puisque  $DEC_{\kappa}(c)$  donne la même sortie à chaque exécution on notera donc  $m := DEC_{\kappa}(c)$  pour designer le caractère déterministe

Il est évident que si l'attaquant détient la clé alors il pourra déchiffrer tous les messages échangés par les entités. Alors qu'en est-il de ENC ? N'est-il pas mieux

de garder tous les deux (l'algorithme et la clé) secret?

Auguste Kerckhoffs a soutenu le contraire à la fin du 19e siècle lors de l'élucidation de plusieurs principes de conception de chiffrements militaires. L'un des plus important d'entre eux, désormais simplement connu sous le nom de principe de Kerckhoff.

### 1.2.2 principe de Kerckhoff

La méthode de chiffrement ne doit pas être tenue secrète, et elle doit pouvoir tomber entre les mains de l'attaquant sans inconvénient.

Pour pouvoir bien comprendre ce principe et voir l'importance de garder la clé secrète nous pouvons considérer l'exemple suivant

Soit  $m$  un message  $\in \{0, 1\}^n$ . On définit notre algorithme de chiffrement (ENC) en faisant la somme directe entre  $m$  et  $\kappa \in K$   $c = m \oplus \kappa$ . On peut voir dans cet algorithme de chiffrement que si  $\kappa$  est fixé alors ce cryptosystème ne sera pas sûr et l'attaquant obtiendra le message initial à partir du chiffré en faisant  $m = c \oplus \kappa$ .

Par contre si  $\kappa$  est choisi de façon uniformément aléatoire dans l'espace des clés  $\{0, 1\}^n$  et gardé secret pour l'attaquant alors le résultat du chiffré sera uniformément distribué dans l'espace des chiffrés  $\{0, 1\}^n$  et la sécurité sera atteinte

### 1.2.3 Principe de Shannon

Un chiffré doit apporter de la confusion et de la diffusion, c'est-à-dire :

#### Confusion

Il n'y a pas de relation algébrique simple entre le clair et le chiffré. En particulier, connaître un certain nombre de couples clair-chiffré ne permet pas d'interpoler la fonction de chiffrement pour les autres messages.

#### Diffusion

La modification d'une lettre du clair doit modifier l'ensemble du chiffré. On ne peut pas casser le chiffre morceau par morceau.

### 1.2.4 Théorème du secret parfait

Avant d'énoncer ce théorème, nous allons considérer les deux exemples ci-dessous

### exemple 1

Considérons l'exemple simple du chiffrement de César suivant

Soit  $\kappa \in \{0, \dots, 25\}$  avec  $\Pr[K = \kappa]$  la probabilité que la clé soit  $\kappa$  (on considère que les clés sont équiprobables) donc  $\Pr[K = \kappa] = \frac{1}{26}$ . Supposons que nous avons la distribution suivante sur  $M$ :  $\Pr[M = a] = 0,7$  et  $\Pr[M = z] = 0,3$ .

( $\Pr[M = a]$  probabilité que le message soit  $a$  et  $\Pr[M = z]$  probabilité que le message soit  $z$ ). Ainsi on cherche alors la probabilité que le message chiffré soit  $B$

On peut voir qu'il n'y a deux possibilités : soit  $M=a$  et  $K=1$ , soit  $M=z$  et  $K=2$ . Par indépendance de  $M$  et  $K$  nous avons  $\Pr[M = a \wedge K = 1] = \Pr[M = a] \cdot \Pr[K = 1]$ , de même  $\Pr[M = z \wedge K = 2] = \Pr[M = z] \cdot \Pr[K = 2]$ .

Par conséquent,

$$\Pr[C = B] = \Pr[M = a \wedge K = 1] + \Pr[M = z \wedge K = 2] = 0,7 \cdot \frac{1}{26} + 0,3 \cdot \frac{1}{26} = \frac{1}{26} \text{ donc } \Pr[C = B] = \frac{1}{26}$$

Nous pouvons également calculer la probabilité conditionnelle par exemple calculer la probabilité que le chiffré  $B$  soit issu de  $a$ ,  $\Pr[a | B]$ . En utilisant le théorème de Bayes nous obtenons :

$$\Pr[M = a | C = B] = \frac{\Pr[C = B | M = a] \cdot \Pr[M = a]}{\Pr[C = B]}$$

Notons que  $\Pr[C = B | M = a] = \frac{1}{26}$ , puisque si  $M = a$  alors la seule voie  $C = B$  peut se produire si  $\kappa = 1$  ce qui se produit avec une probabilité de  $\frac{1}{26}$

$$\text{Donc } \Pr[M = a | C = B] = \frac{\Pr[C = B | M = a] \cdot \Pr[M = a]}{\Pr[C = B]} = \frac{\frac{1}{26} \cdot 0,7}{\frac{1}{26}}$$

$$\Pr[M = a | C = B] = 0,7$$

Conclusion

on a  $\Pr[M = a] = \Pr[M = a | C = B] = 0,7$ .

Ce résultat montre que la probabilité d'avoir une information claire sur le message ne varie pas même si on connaît son chiffré  $B$

### exemple 2

Considérez à nouveau le chiffre de décalage, mais avec la distribution suivante sur  $M$ :

$$\Pr[M = kim] = 0,5, \Pr[M = ann] = 0,2, \Pr[M = boo] = 0,3$$

Calculons alors la probabilité pour que le chiffré  $C$  soit égale à  $DQQ$ . La seule façon dont ce chiffré peut se produire est si  $M = ann$  et  $K = 3$ , ou  $M = boo$  et  $K = 2$ , ce qui arrive avec la probabilité  $0,2 \cdot \frac{1}{26} + 0,3 \cdot \frac{1}{26} = \frac{1}{52}$ .

Nous pouvons également calculer la probabilité que le chiffré DQQ soit issu de ann.? Un calcul comme ci-dessus en utilisant le théorème de Bayes donne  $Pr[M = ann \mid C = DQQ] = 0,4$

conclusion

On a  $Pr[M = ann] \neq Pr[M = ann \mid C = DQQ]$  dans cet exemple nous avons vu avec cette distribution que la probabilité d'avoir une information claire ann varie si son chiffré DQQ est connu

## Commentaire

Nous pouvons maintenant définir la notion de secret parfait. On imagine un adversaire qui connaît la distribution de probabilité de M c'est-à-dire que l'adversaire connaît la probabilité que différents messages soient envoyés.

L'adversaire connaît également le schéma de chiffrement utilisé. La seule chose inconnue de l'adversaire est la clé partagée par les parties. Un message est choisi par l'une des parties et chiffré, et le texte chiffré résultant est transmis à l'autre partie. L'adversaire peut espionner la communication des parties, et ainsi observer ce texte chiffré. (Autrement dit, c'est une attaque de texte chiffré uniquement « ciphertext-only attack », où l'attaquant ne voit qu'un seul texte chiffré.)

Dans un schéma parfaitement secret, l'observation de ce texte chiffré ne devrait avoir aucun effet sur la connaissance de l'adversaire concernant le message réel qui a été envoyé; autrement dit, la probabilité a posteriori qu'un message  $m \in M$  ait été envoyé, conditionné par le texte chiffré qui a été observé, ne devrait pas être différente de la probabilité a priori que  $m$  serait envoyé. Cela signifie que le texte chiffré ne révèle rien sur le message envoyé sous-jacent et que l'adversaire n'apprend absolument rien sur le texte en clair qui a été chiffré. Formellement

## Définition 1

Un cryptosystème (GEN, ENC, DEC) avec M l'espace de messages est parfaitement secret si pour toute distribution de probabilité sur M et  $\forall m \in M$  et  $c \in C$  tel que  $Pr[C=c]>0$  on a ;

$$Pr[M = m \mid C = c] = Pr[M = m].$$

(L'exigence que  $Pr[C = c] > 0$  est une condition nécessaire pour éviter le conditionnement sur un événement à probabilité nulle.)

Nous pouvons voir que le chiffrement de César n'est pas parfaitement secret



### **Théorème du secret parfait, Shannon**

Soit  $(M, K, C, \text{GEN}, \text{ENC}, \text{DEC})$  un cryptosystème. On suppose que  $\#M = \#K = \#C < \infty$  et que  $\Pr[M=m] > 0 \forall m \in M$ . Alors ce cryptosystème est à secret parfait Si seulement si

- La distribution des clés suit une loi uniforme
- pour tout clair  $m$  appartient à  $M$

$$\phi_m = \begin{cases} K \longrightarrow C \\ \kappa \longrightarrow \text{ENC}_\kappa(m) \end{cases}$$

est une bijection

### **Démonstration**

On suppose avoir secret parfait. On montre d'abord la bijectivité, puis l'équiprobabilité.

**Bijectivité**

S'il existe  $m$  tel que  $\phi_m : k \mapsto \text{ENC}_k(m)$  est non surjective, il existe  $c \in C$  tel que  $\forall \kappa \in K, \text{ENC}_\kappa(m) \neq c$ . En particulier  $\Pr[C = c | M = m] = 0$ , d'où l'on tire  $\Pr[M = m | C = c] = 0 \neq \Pr[M = m] > 0$  impossible. Donc  $\phi_m$  est surjective, et par égalité des cardinaux bijective.

**Equiprobabilité**

Soit  $c \in C$  un chiffré fixé. Pour tout  $m \in M$ , on note  $\kappa(m)$  l'unique clef telle que  $\text{ENC}_{\kappa(m)}(m) = c$  (d'après la bijectivité). On a  $\Pr[M = m | C = c] = \Pr[K = \kappa(m)]$

Puisque par hypothèse  $\Pr[M = m | C = c] = \Pr[M = m]$ , on obtient  $\Pr[K = \kappa(m)] = \Pr[C = c]$ . Or le chiffrement  $m \mapsto \text{ENC}_k(m)$  est injectif à clef fixé, donc bijectif. Donc pour toute clef  $\kappa$ , il existe  $m$  tel que  $\kappa = \kappa(m)$ .

Ainsi,  $\Pr[K = \kappa] = \Pr[K = \kappa(m)] = \Pr[C = c]$  est constante, et vaut  $\frac{1}{\#K}$

Dans le sens réciproque, il suffit d'effectuer le calcul : par équiprobabilité des clefs

## 1.3 définition de sécurité pour la cryptographie à clé privée

Avant de parler de la sécurité, nous allons définir formellement ce que signifie être sûr pour un système cryptographique. La sécurité d'un cryptosystème est évaluée du fait qu'un adversaire efficace peut ou non différencier ou distinguer le chiffré de deux textes clairs dans une preuve par jeux donnée.

### Fonction négligeable

Une fonction  $F$  de  $\mathbf{N} \rightarrow \mathbf{R}$  est dite négligeable si pour tout polynôme  $P$  il existe  $n_0 \in \mathbf{N}$  tel que pour tout  $n > n_0$  on a :

$$F(n) < \frac{1}{P(n)}$$

Dans ce qui suit le terme on utilisera le terme « sécurité eav » pour désigner la sécurité du preuve par jeu en présence d'un espion comme noté dans la [4]

### 1.3.1 sécurité EAV

#### indistinguabilité

On considère une expérience notée  $\text{PrivK}^{eav}$  dans lequel un adversaire  $A$  émet deux messages  $m_0, m_1$  et reçoit le chiffré d'un de ces messages. La définition de l'indistinguabilité stipule qu'un schéma  $E$  est sûr si aucun adversaire  $A$  ne peut déterminer lequel des deux messages a été chiffré on dit alors que le cryptosystème est indistinguishable

#### Définition de l'expérience

L'expérience est définie pour un schéma de chiffrement à clé privée  $E = (\text{GEN}, \text{ENC}, \text{DEC})$ , un adversaire  $A$ , et une valeur  $n$  pour le paramètre de sécurité :

1) L'adversaire  $A$  émet deux messages  $m_0, m_1 \in M$

2) Une clé  $\kappa$  est générée à l'aide de l'algorithme  $\text{GEN}$ , inconnue de l'adversaire de plus un bit aléatoire  $b \in \{0, 1\}$  est choisi pour sélectionner  $m_0, m_1$ . On calcule  $c = \text{ENC}_\kappa(m_b)$  et on donne le chiffré  $c$  à  $A$  comme challenge

3)  $A$  émet alors un bit  $b'$  dans le but d'avoir  $b' = b$

4 ) Le résultat de l'expérience est 1 si  $b'=b$  et 0 sinon .Dans le cas ou le résultat est 1 on dit que A a réussi et on note  $\text{PrivK}^{eav}_{A,E} = 1$   
Ainsi formellement nous pouvons définir la « sécurité EAV » comme suit

## Définition 2

Un schéma de chiffrement à clé privée  $E = (\text{GEN}, \text{ENC}, \text{DEC})$  est indistinguishable sous une attaque eav(attaque en présence d'espion) si pour tout algorithme probabiliste ,il existe une fonction négligeable  $\text{negl}$  telle que

$$\Pr[\text{PrivK}^{eav}_{A,E}(n) = 1] \leq \frac{1}{2} + \text{negl}(n)$$

Où la probabilité est prise aléatoirement et l'expérience également (c'est-à-dire le choix de la clé, du bit  $b$  ainsi que tout paramètre utilisé par ENC).

### 1.3.2 Attaque par texte clair choisi (Chosen plaintext Attack CPA)

Formellement, nous modélisons les attaques par texte choisi en donnant à l'adversaire A l'accès à un oracle de chiffrement, vu comme une "boîte noire" qui chiffre les messages choisis par A à l'aide d'une clé  $k$  inconnue de lui. Autrement dit, nous imaginons que A a accès à un "oracle"  $\text{ENC}_k(-)$  ; lorsque A interroge cet oracle en lui fournissant un message  $m$  comme entrée, l'oracle renvoie un texte chiffré  $c \leftarrow \text{ENC}_k(m)$  comme réponse. (Si ENC est randomisé, l'oracle utilise un nouvel aléa chaque fois qu'il répond à une requête). L'adversaire peut interagir avec l'oracle de chiffrement de manière adaptative, autant de fois qu'il le souhaite.

Considérons l'expérience suivante définie pour tout schéma de chiffrement  $E = (\text{GEN}, \text{ENC}, \text{DEC})$ , l'adversaire A, et la valeur  $n$  pour le paramètre de sécurité :

- 1.) Une clé  $k$  est générée en utilisant GEN. L'adversaire A, qui ne connaît pas la clé, est autorisé à effectuer un nombre polynomial de requêtes à un oracle de chiffrement  $\text{ENC}_k$ .
- 2.) A émet deux messages  $m_0, m_1 \in M$
- 3.) On choisit un bit aléatoire  $b \in \{0, 1\}$ . On calcule  $c = \text{ENC}_k(m_b)$  et on

donne le chiffré  $c$  à  $A$  comme le challenge

4.)  $A$  continue à avoir accès à l'oracle de chiffrement  $ENC_K$ .

5.)  $A$  sort un bit  $b'$  dans le but d'avoir  $b' = b$

6.) La sortie de l'expérience est 1 si  $b' = b$  et 0 sinon. Nous appelons le premier cas le succès de  $A$  et le désignons par  $PrivK^{cpa}_{A,E} = 1$

.

### Définition 3

Un schéma de chiffrement à clé privée  $E = (GEN, ENC, DEC)$  est sûr en cas d'attaque par texte plat choisi (CPA) si, pour tous les adversaires probabilistes en temps polynomial  $A$ , il existe une fonction négligeable  $negl$  telle que

$$\Pr[PrivK^{cpa}_{A,E}(n) = 1] \leq \frac{1}{2} + negl(n)$$

### proposition 1

Un schéma de chiffrement  $E$  dont l'algorithme de chiffrement  $ENC$  est déterministe ne peut pas être CPA-sûr

### Démonstration

Considérons l'adversaire  $A$  suivant qui joue le jeu de sécurité CPA comme suit :

- 1.) Sélectionner deux messages aléatoires distincts  $m_0, m_1 \in M$ .
- 2.) Utiliser l'oracle de chiffrement pour obtenir les chiffrés  $c_0 = ENC_K(m_0)$  et  $c_1 = ENC_K(m_1)$ .

3.) Sortir les deux messages  $m_1, m_1 \in M$

4.) A la réception du texte chiffré  $c$ , si  $c = c_0$ , sortir le bit 0, sinon sortir le bit 1.

Comme  $ENC$  est déterministe, le texte chiffré du challenge  $c$ , étant un chiffrement de  $m_0$  ou  $m_1$ , sera égal à  $c_0$  ou  $c_1$ . Ainsi,  $A$  pourra réussir avec une probabilité non négligeable sur  $\frac{1}{2}$  (en particulier,  $A$  réussira toujours). Ainsi,  $E$  ne peut pas être CPA-sûr

### 1.3.3 Attaque à chiffré choisi (Chosen Cipher text Attack)(CCA)

Qu'est-ce que cela signifie pour un schéma de chiffrement de résister contre les attaques à chiffre choisi ? Comme d'habitude pour définir une notion de sécurité

appropriée, nous devons définir deux choses : la capacité supposée de l'attaquant et ce qui constitue une attaque réussie. Pour ce dernier nous suivrons l'approche adoptée dans les définitions précédentes. Nous allons donc donner à l'attaquant un texte chiffré  $c$  comme challenge issu des messages  $m_0$  ou  $m_1$  (chacun choisi avec une probabilité égale) et on considère que le schéma est cassé si l'attaquant peut déterminer lequel des deux messages a été chiffré avec une probabilité significative meilleur que  $\frac{1}{2}$ .

L'attaque par chiffré choisi (CCA) permet à l'adversaire de disposer à la fois d'un oracle de chiffrement et de déchiffrement qu'il peut interroger à tout moment pendant le jeu.

D'autres textes distinguent les attaques par chiffré choisi non adaptative et les attaques par chiffrés choisis adaptative. Les premières également appelé lunchtime permettent seulement à l'adversaire d'utiliser l'oracle de déchiffrement avant de recevoir le challenge (le chiffré). La seconde un modèle d'attaque beaucoup plus puissant permet à l'adversaire de continuer d'utiliser l'oracle de déchiffrement après avoir reçu le challenge, mais évidemment il n'est pas autorisé à interroger l'oracle de déchiffrement avec le challenge. Dans ce mémoire nous faisons allusion à la seconde cas lorsque nous parlerons d'attaque CCA. Comme nous pouvons le voir la sécurité CCA est beaucoup plus forte que la sécurité CPA ou EAV et les implique tous les deux. Nous présenterons les définitions formelles ci-dessous.

Considérons l'expérience suivante définie pour tout schéma de chiffrement  $E = (\text{GENC}, \text{ENC}, \text{DEC})$ , l'adversaire  $A$ , et la valeur  $n$  pour le paramètre de sécurité :

- 1) Une clé est générée à l'aide de l'algorithme de génération des clés GEN. L'adversaire  $A$  qui ne connaît pas la clé, peut effectuer un nombre polynomial de requête à un oracle de chiffrement et de déchiffrement.
- 2)  $A$  émet deux messages  $m_0, m_1$ .
- 3) On choisit un bit aléatoire  $b \in \{0, 1\}$ . On calcule  $c = \text{ENC}_\kappa(m_b)$  et on donne  $c$  à  $A$  comme challenge.
- 4)  $A$  continue à avoir accès à l'oracle de chiffrement et de déchiffrement mais avec la restriction que  $A$  ne peut pas exécuter l'oracle de déchiffrement sur le challenge  $c$ .
- 5)  $A$  produit un bit  $b'$  dans le but d'avoir  $b' = b$ .

6)Le resultat de l'experience est 1 si  $b'=b$  et 0 sinon Si  $b= b'$  nous disons que A a réussi et nous le désignons par  $\text{PrivK}^{cca}_{A,E} = 1$

.

### Définition 3

Un schéma de chiffrement à clé privée  $E = (\text{KeyGen}, \text{Enc}, \text{Dec})$  est ,(CCA) sûr si, pour tous les adversaires probabilistes en temps polynomial A, il existe une fonction négligeable  $\text{negl}$  telle que

$$\Pr[\text{PrivK}^{cca}_{A,E}(n) = 1] \leq \frac{1}{2} + \text{negl}(n)$$

## 1.4 Cryptographie à clé publique

### 1.4.1 Fonction à sens unique

Une fonction  $f : A \rightarrow B$  est dite à sens unique s'il est facile à calculer  $f(x)$  pour tout  $x \in A$  (complexité polynômiale) et est difficile (complexité exponentielle) pour presque tout  $y \in B$ , de trouver  $x$  tel que  $y = f(x)$ .

Une fonction est à sens unique avec trappe si l'on connaît un secret permettant de l'inverser

### 1.4.2 Fonction de hashage

$\{0, 1\}^*$  ensemble des chaines de longueur quelconque,  $\{0, 1\}^l$  ensemble des chaines longueur fixe avec  $l \neq 0$ .

#### définition 3

Une fonction  $H : \{0, 1\}^* \rightarrow \{0, 1\}^l$  est dite fonction de hachage si :

1. Pour tout  $x$ ,  $H(x)$  est facile à calculer,  $H(x)$  est appelé le hash ou l'empreinte de  $x$
2. Étant donné  $H(x)$ , il est difficile de trouver  $y$  tel que  $y = H(x)$  (fonction à sens unique) ;
3. Étant donné  $x$ , il est difficile de trouver  $x'$  tel que  $x \neq x'$  et  $H(x) = H(x')$ , (collusions faibles) ;

4. Il est difficile de trouver  $x$  et  $x'$  (de son choix)  $x \neq x'$  tel que  $H(x) = H(x')$ , (collusions fortes) ;

### 1.4.3 Modélisation du chiffrement à clés publique

Un schéma de chiffrement à clé publique de  $E=(\text{GEN},\text{ENC},\text{DEC})$  avec un espace de clés  $\mathcal{K} = \mathcal{K}_{k,s} \times \mathcal{K}_{k,p}$ , un espace de message  $\mathcal{M}$  et un espace chiffré  $\mathcal{C}$  est un 3-tuple d'algorithme efficace dans lequel :

$\text{GEN} : \lambda \longrightarrow \mathcal{K}$  algorithme de génération des clés

$\text{ENC}_\kappa : \mathcal{M} \longrightarrow \mathcal{C}$  est une fonction à sens unique (avec trappe qui est un inverse à gauche) appelée fonction de chiffrement et qui dépend d'un paramètre  $\kappa$  appelé clé(publique)

$\text{DEC}_{\kappa'} : \mathcal{C} \longrightarrow \mathcal{M}$  est la trappe et est appelée fonction de déchiffrement (dépendant de la clé  $\kappa'$ ) et on a  $\text{DEC}_{\kappa'}(\text{ENC}_\kappa(m)) = m$

Il existe des définitions identiques pour la sécurité EAV, CPA et CCA pour les systèmes de chiffrements à clé publique. Nous renvoyons le lecteur à [7] pour les détails.

#### proposition 2

Un cryptosystème à clé publique est EAV-sûr si et seulement il est Cpa-sûr

#### Démonstration

Dans la version à clé publique du jeu de sécurité EAV, l'adversaire  $A$  a accès à la clé publique  $pk$ . Par conséquent,  $A$  peut calculer  $\text{Enc}_{pk}(m)$  lui-même pour tout message  $m$ , ce qui est équivalent à donner à  $A$  l'accès à un oracle de chiffrement. Par conséquent, pour les schémas de chiffrement à clé publique, la sécurité EAV est équivalente à la sécurité CPA.

---

---

# CHAPTER 2

---

## LE CHIFFREMENT HOMOMORPHE

### 2.1 Introduction

A présent que nous avons vu les notions préliminaires de la cryptographie, nous pouvons entamer la théorie du chiffrement homomorphe.

Dans ce chapitre nous introduisons le concept du chiffrement homomorphe de manière formelle mais aussi par analogie en utilisant l'exemple de la bijouterie présenté dans [3]. Ensuite nous allons parler de l'efficacité et de la sécurité du chiffrement homomorphe.

### 2.2 Concept du chiffrement homomorphe

#### 2.2.1 Modélisation du chiffrement homomorphe

##### Définition

Un cryptosystème homomorphe  $\varepsilon = (\text{GEN}, \text{ENC}, \text{DEC}, \text{Evaluate}, \mathcal{F})$  avec  $\mathcal{K}$  espace des clés,  $\mathcal{M}$  espace des textes clairs,  $\mathcal{C}$  espace des textes chiffrés et  $\lambda$  le paramètre de sécurité est un 5 uplet dont:

$\text{GEN} : \lambda \rightarrow \mathcal{K}$  est l'algorithme de génération des clés

$\text{ENC} : \mathcal{K} \times \mathcal{M} \rightarrow \mathcal{C}$  est l'algorithme de chiffrement

$\text{DEC} : \mathcal{K} \times \mathcal{C} \rightarrow \mathcal{M}$  l'algorithme de déchiffrement

$\text{Evaluate} : \mathcal{F} \times \mathcal{C}^* \rightarrow \mathcal{C}$  est la fonction d'évaluation qui prend en entrée une fonction autorisée  $f \in \mathcal{F}$  et l'évalue sur un ensemble de texte chiffré  $(c_1, c_2, \dots, c_n)$  pour produire un autre chiffré  $c$ .



La définition ci-dessus stipule que si  $f$  représente une fonction de traitement alors on peut faire du traitement (évaluer) sur les données sans en avoir accès. Cela peut sembler paradoxal ou voir impossible, mais pour ce faire une idée de la solution, on peut considérer l'exemple suivant présenté dans l'étude de Gentry de 2010 [3].

Dans cet exemple Alice possède une bijouterie. Elle prend des matières premières dans son magasin (or, diamant...) et les transforme en coliers et bagues. Alice doit s'occuper de la commande de ses clients et elle est donc obligée de laisser à ses employés faire la transformation. Cependant Alice ne fait pas confiance à ses employés et elle craint qu'ils ne volent certaines matières premières à son insu. La solution d'Alice à cette énigme est la suivante. Elle crée une boîte dans laquelle elle seule a accès grâce à une clé. La boîte est accompagnée de gants qui permettent de manipuler les objets qui s'y trouvent mais ne permettent pas de sortir quoi que soit de la boîte. Ensuite Alice met les matières premières dans la boîte et la ferme avec sa clé pour que son contenu ne puisse pas être retiré et demande à ses employés d'assembler les bijoux en utilisant les gants fournis par la boîte. Ainsi Alice utilise sa clé pour ouvrir la boîte et récupérer les bijoux assemblés.

Comme le note Gentry, cette analogie présente en effet des insuffisances, même si les employés ne peuvent pas sortir les matériaux, ils peuvent voir s'ils sont présents ou non et mieux ce que la boîte contient, ce qui ne correspond pas aux exigences de sécurité de la cryptographie. Cependant l'exemple démontre suffisamment l'idée principale du chiffrement homomorphe.

Une autre analogie, plus réaliste, est la suivante : supposons que la scolarité du département de LACGAA de l'UCAD conserve des dossiers détaillés sur tous ses étudiants et leurs résultats. Ainsi la scolarité décide de stocker toutes ces données chiffrées évidemment sur un service cloud. Ainsi les administrateurs de la scolarité veulent calculer à partir des données stockées sur le cloud la moyenne de chaque étudiant. Cependant ils ne veulent pas compromettre les données personnelles des étudiants en donnant au service tiers (le cloud) la clé secrète.

Dans ce cas si les administrateurs utilisent le chiffrement homomorphe où la moyenne sera une fonction autorisée ( $\mu \in F$ ), le service tiers (cloud) pourra évaluer alors la moyenne des étudiants sur les données chiffrées et le renvoyer à son tour aux administrateurs de la scolarité qui pourront alors utiliser leur clé secrète pour déchiffrer la moyenne chiffrée des étudiants.

Notez que nous supposons que le service en cloud suit un modèle honnête mais curieux, ce qui signifie qu'il exécutera les instructions correctement (c'est-à-dire qu'il calculera la fonction de chiffrement souhaitée au lieu d'une fonction malveil-

lante de son choix), mais s'il en a l'occasion, il essaiera d'obtenir des informations sur les données sous-jacentes chiffrés qu'il stocke.

Cependant, il existe un cryptosystème homomorphe trivial qui satisfait à notre définition du chiffrement homomorphe, où la fonction Evaluate ajoute simplement la description de la fonction aux chiffrés correspondants, et l'algorithme DEC se charge de l'évaluation de la fonction on a alors:

$$\text{Evaluate}(f, c_1, \dots, c_n) = (f, c_1, \dots, c_n) = c$$

L'algorithme DEC fait l'évaluation  $\text{DEC}(c) = f(\text{DEC}(c_1), \dots, \text{DEC}(c_n))$

## Definition 2

Un schéma de chiffrement est dit compact si le temps d'exécution du déchiffrement du chiffré évalué  $c$  (sortie de Evaluate) est égale au temps d'exécution du déchiffrement des chiffrés par lesquels il est créé  $c_i$  (entrée de Evaluate). La taille  $c$  ne peut pas être plus grande que la taille des  $c_i$  et le temps de déchiffrement de  $c$  doit être indépendant de la complexité de  $f$ , la fonction permise choisie.

## définition 3

Un schéma de chiffrement homomorphe est dit à  $i$ -saut ( $i$ -hop homomorphe) s'il est possible d'appliquer le résultat de l'algorithme d'évaluation  $i$  fois de suite.

Une propriété intéressante que nous donne la compacité est que nous pouvons transformer un schéma de chiffrement homomorphe à clé privée en un schéma homomorphe à clé publique en particulier nous avons ce théorème suivant tiré de [6]

## Théorème

Tout schéma de chiffrement à clé privée sécurisé à messages multiples qui est compact et homomorphe par rapport à l'addition modulo 2 peut être transformé en un schéma à clé publique sémantiquement sûr.

En particulier, si le schéma à clé privée permet  $i + 1$  évaluations de la fonction d'évaluation homomorphe ( $(i+1)$ -hop homomorphe) alors le schéma à clé publique correspondant permet  $i$  évaluations de la fonction d'évaluation homomorphe ( $i$ -hop homomorphe)

## Démonstration

Voir [6] pour deux constructions explicites qui transforment de tels schémas de chiffrement à clé privée en schémas à clé publique.

## 2.3 Sécurité des cryptosystèmes homomorphe

Par rapport à la sécurité des schémas de chiffrement homomorphes, il est important de réfléchir sur le modèle d'attaque du serveur tiers (l'évaluateur) et voir ce qu'il est capable de faire. Dans l'exemple précédent nous avons supposé que le modèle est honnête mais curieux ce qui signifie que la partie tierce (serveur) suivra et exécutera les instructions correctement et essaiera d'en apprendre le plus possible sur les données chiffrées.

Notez qu'il y a d'autres modèles beaucoup plus adverses que nous pouvons considérer pour le serveur (par exemple, il ne calcule pas toujours la fonction appropriée), mais ces obstacles présentés peuvent être résolus en utilisant la délégation de calcul. Cette dernière permet d'établir un protocole pour qu'un tiers calcule une fonction et prouve efficacement qu'il a correctement calculé la fonction. Nous allons pas dans ce mémoire traiter la délégation des chiffrements homomorphe nous renvoyons le lecteur aux sources comme [8]

Une caractéristique des cryptosystèmes homomorphes qui a des implications importantes pour la sécurité est la malléabilité.

### 2.3.1 La Malléabilité

#### Définition 3

Un schéma de chiffrement  $E$  est malléable si, étant donné le texte chiffré d'un message,  $c = ENC_K(m)$ , il existe une fonction non constante  $f$  qui n'est pas la fonction d'identité, de sorte qu'un adversaire efficace  $A$  peut calculer le texte chiffré d'un certain message lié  $c'$  tel que  $DEC_K(c') = f(m)$  avec une probabilité non négligeable.

Les cryptosystèmes homomorphes sont malléables par définition puisqu'ils permettent l'évaluation de diverses fonctions sur des chiffrés. Les cryptosystèmes malléables sont intrinsèquement limités dans la sécurité qu'ils offrent. Les chercheurs ont montré que plus que le système est malléable, plus qu'il est facile à casser. Comme

les cryptosystème homomorphes sont malléables , nous avons donc la limitation suivante sur leur sécurité

### proposition 1

Tout schéma de chiffrement malléable ne peut pas être sécurisé contre les attaques adaptatives par chiffré choisi(CCA).

### Démonstration

Soit  $E=(GEN,ENC,DEC,F,Evaluate)$  un cryptosystème homorphe malléable où pour un certain message  $m_0$  ,et pout tout  $c \in$

$C_m = \{c \in C \mid \Pr[ENC_{\kappa}(m_0) = c] \text{ avec } \kappa \text{ et } ENC \text{ aléatoire}\}$  Comme E est mal-léable alors le message  $f(m)$  a un chiffré de la forme  $g(c)$  pour tout  $c \in C_m$  où  $f, g$  peuvent être calculés en temps polynomial. Comme  $f$  est non constante, il existe un message  $m_1$  tel que  $f(m_1) \neq f(m_0)$ . Alors, on considère l'adversaire l'adversaire A suivant :

- 1.) Soumet  $m_0$  à l'oracle de chiffrement, et note  $c_0 = ENC_{\kappa}(m_0)$
- 2.) Sort les messages  $f(m_0)$  et  $f(m_1)$
- 3.) A la réception du texte chiffré de défi  $c$ , A calcule  $g(c_0)$ . Si  $c = g(c_0)$ , alors la sortie  $b = 0$ . Sinon, tirer à pile ou face et sortir le résultat. Nous pouvons voir qu'un tel adversaire obtiendrait un avantage non négligeable, et donc notre schéma de chiffrement malléable E n'est pas sûr contre les attaques adaptatives par texte choisi.

À partir de là, nous nous rendons compte que, bien qu'il existe des schémas de chiffrement, même à clé publique, qui sont sûrs contre les attaques par texte chiffré choisi adaptatif [1], il est impossible de construire un schéma de chiffrement homomorphe qui satisfasse à cette exigence de sécurité. Cela dit, bien que les schémas de chiffrement homomorphes ne puissent pas formellement répondre à l'exigence de la CCA, nous pouvons les augmenter avec des méthodes de délégation de calcul qui peuvent aider à garantir que le serveur ne modifie pas de manière malveillante les chiffrés qu'il renvoie, ce qui est le type d'attaque qui motive le désir d'une sécurité CCA [8]. Il existe également de nombreuses d'autres normes de sécurité que les schémas de chiffrement homomorphes sont capables d'atteindre, comme la sécurité EAV et la sécurité CPA [4].

Les définitions de sécurité d'un chiffrement homomorphe sont les mêmes que

celles d'un schéma de chiffrement simple. Pour un schéma de chiffrement régulier, imposant des conditions sur les opérations GEN, ENC, DEC, mais étant indépendantes de l'opération Evaluate.

---

---

## CHAPTER 3

---

# NOTION PRÉLIMINAIRES DE MACHINE LEARNING

### 3.1 Introduction

Dans cette section, nous allons voir quelques algorithmes de machine learning qui seront combinés ultérieurement avec les schémas de chiffrements homomorphes. Nous allons étudier les algorithmes d'apprentissage supervisé et non supervisé.


L'apprentissage supervisé consiste à déduire une fonction (modèle) à partir d'un ensemble de données étiquetées. Les deux types d'apprentissage supervisé sont la classification et la régression, le premier faisant référence au cas où les étiquettes forment un ensemble discret d'étiquettes de classe, et le second lorsque les étiquettes prennent des valeurs continues. Pour la classification, nous examinerons l'analyse discriminante linéaire, la classification naïve bayésienne et les arbres de décision.

D'autre part, l'apprentissage non supervisé consiste à déduire la structure cachée des données non étiquetées. Pour le cas de l'apprentissage non supervisé, nous allons voir l'analyse en composantes principales, qui est également un outil important pour la réduction de la dimension.

## 3.2 Classification binaire

La classification binaire est un problème consistant à prendre un vecteur de caractéristiques  $\mathbf{x}$  et à décider de laquelle des deux étiquettes (ou classes) il appartient. Par exemple on peut prendre un vecteur de caractéristiques contenant la taille et le poids d'une personne et essayer de prédire le sexe de la personne. Il existe de nombreux algorithmes qui traitent ce problème, notamment la régression logistique, les machines à vecteurs de support, etc. Dans cette section, nous examinerons la discrimination linéaire de Fisher, qui est une technique permettant d'effectuer une classification binaire lorsque les caractéristiques sont des quantités continues.

L'analyse discriminante linéaire de Fisher aborde le problème de la classification en trouvant un vecteur  $\mathbf{w}$  sur lequel nous pouvons projeter les données sur un vecteur tel qu'il est plus facile de définir un point qui sépare les deux classes avec une grande marge. Pour ce faire, nous choisissons un vecteur  $\mathbf{w}$  qui maximise le rapport entre les variances interclasse et intraclasse. Intuitivement, cela a du sens car nous voulons maximiser la séparation entre les différentes classes, tout en minimisant la séparation au sein de chaque classe. Une fois que nous avons ce vecteur  $\mathbf{w}$ , nous pouvons classer un point de données  $\mathbf{x}$  en calculant  $\mathbf{w}^T \mathbf{x}$  et en le comparant au seuil  $c$  correspondant à notre point de séparation.



De manière plus formelle, considérons un problème à deux classes dans lequel il y a  $N_1$  points de la classe  $C_1$  et  $N_2$  points de la classe  $C_2$ , de sorte que les vecteurs

moyens des deux classes sont donnés par:

$$u_1 = \frac{1}{N_1} \sum_{i=1}^n X_i, \text{ et } u_2 = \frac{1}{N_2} \sum_{i=1}^n X_i \quad (3.1)$$

La mesure la plus simple de la séparation des classes, lorsqu'elle est projetée sur  $w$ , est la séparation des moyennes des classes projetées. Ceci suggère que nous pourrions choisir  $w$  de manière à maximiser

$$u_2 - u_1 = \mathbf{w}^T(u_2 - u_1) \quad (3.2)$$

$$u_k = \mathbf{w}^T(u_k) \quad (3.3)$$

La variance intra-classe des données transformées de la classe  $C_k$  est donc donnée par

$$\sigma_k^2 = \sum_{n \in C_k} (Y_n - u_k)^2 \quad (3.4)$$

où

$$Y_n = \mathbf{w}^T x_n \quad (3.5)$$

Nous pouvons définir la variance intra-classe totale pour l'ensemble des données comme étant simplement  $\sigma_1^2 + \sigma_2^2$ . Le critère de Fisher est défini comme étant le rapport entre la variance interclasse et la variance interne à la classe et est donné

par:

$$\begin{aligned}
 S &= \frac{\sigma^2_{(intra)}}{\sigma^2_{(extra)}} \\
 &= \frac{(u_2 - u_1)^2}{\sigma_1^2 + \sigma_2^2} \\
 &= \frac{(\mathbf{w}^\top (u_2 - u_1))^2}{(\sum_{i,c_i=1} (\mathbf{w}^\top (x_i - u_1)))^2 + (\sum_{i,c_i=2} (\mathbf{w}^\top (x_i - u_2)))^2} \\
 &= \frac{\mathbf{w}^\top \mathbf{S}_B \mathbf{w}}{\mathbf{w}^\top \mathbf{S}_W \mathbf{w}}
 \end{aligned}
 \tag{3.6}$$

où  $\mathbf{S}_B$  est la matrice de covariance entre les deux classes  $C_1$  et  $C_2$  avec

$$\mathbf{S}_B = (u_2 - u_1)(u_2 - u_1)^\top \tag{3.7}$$

et  $\mathbf{S}_W$  la matrice de covariance intra-classe avec

$$\mathbf{S}_W = \sum_{i,c_i=1} (x_i - u_1)(x_i - u_1)^\top + \sum_{i,c_i=2} (x_i - u_2)(x_i - u_2)^\top \tag{3.8}$$

En suivant la présentation de [5], nous pouvons deriver par rapport à  $\mathbf{w}$  pour obtenir

$$\frac{\partial S}{\partial \mathbf{w}} = 0 \Rightarrow (\mathbf{w}^\top \mathbf{S}_B \mathbf{w}) \mathbf{S}_W \mathbf{w} = (\mathbf{w}^\top \mathbf{S}_W \mathbf{w}) \mathbf{S}_B \mathbf{w} \tag{3.9}$$

$\mathbf{S}_B \mathbf{w}$  est dans la même direction que  $u_2 - u_1$  et que  $(\mathbf{w}^\top \mathbf{S}_B \mathbf{w})$  et  $(\mathbf{w}^\top \mathbf{S}_W \mathbf{w})$  sont des constantes. Puisque nous ne nous intéressons qu'à la direction et non au facteur de  $\mathbf{w}$ , nous pouvons eliminer les constantes et multiplier les deux côtés par  $\mathbf{S}_W^{-1}$  pour obtenir une solution optimale de  $\mathbf{w}$

$$\mathbf{w}^* \propto \mathbf{S}_W^{-1}(u_2 - u_1)$$

Une fois que le  $\mathbf{w}$  optimale calculé ,nous devons trouver un seuil de classification  $c$ . D'habitude  $c$  est pris comme etant le point médian entre les deux moyennes dans la direction donnée par  $\mathbf{w}^*$ .

$$c = \frac{\mathbf{w}^{*\top} (u_2 - u_1)}{2} \tag{3.10}$$

Ainsi, étant donné un point  $x$ , on calcule  $\mathbf{w}^{*\top} x$  et on classe  $x$  selon que cette valeur est supérieure ou inférieure à  $c$  (seuil).



### 3.3 Classification naïve bayésienne

Un classificateur Naïve Bayes est une méthode pour classer des vecteurs caractéristiques à valeur discrète. En particulier, étant donné un vecteur de données  $\mathbf{x} \in \{1, \dots, K\}^n$ , où  $K$  est le nombre de valeurs possibles pour chaque variable caractéristique et  $D$  est le nombre de variable caractéristiques. Cela nous permet d'écrire la densité conditionnelle de classe comme suit :

$$P(\mathbf{x} \mid C = c) = \prod_{j=1}^D P(x_j \mid C = c) \quad (3.11)$$

Les classificateurs de Naïve Bayes sont qualifiés de “naïves” car ils supposent l'indépendance des variables ,ce qui est rarement le cas .Malgré cela , ils donnent parfois de bon résultat [2]

Comme son nom l'indique, les classificateurs Naïve Bayes constituent une autre façon d'aborder le problème de la classification. Si nous avons  $K$  classes possibles, alors le modèle se compose de classe de probabilité à priori  $\{Pr(C = c_i)\}_{i=1}^K$  (c'est-à-dire la probabilité à priori de la classe  $c_i$ ) et des densités conditionnelles de classe  $\{P(X = x \mid C = c_i)\}_{i=1}^K$ , c'est-à-dire la probabilité qu'un objet de la classe  $c_i$  possède un ensemble de variables caractéristiques  $\mathbf{x}$ .

À titre d'exemple , supposons que nous ayons une liste de maladies  $\{m_1, \dots, m_n\}$  et un vecteur de symptômes  $(s_1, \dots, s_m)$  où  $s_i=1$  si la personne présente le symptôme  $i$  et 0 si elle ne le présente pas. Le modèle de Naïve Bayes spécifie  $P(s_i = 1 \mid m_j) \forall i, j$  (c'est-à-dire la probabilité qu'une personne présente le symptôme  $i$  étant donné qu'elle est atteinte de la maladie  $j$ ) et  $P(m_j) \forall j$  (c'est-à-dire la probabilité qu'une personne soit atteinte de la maladie  $j$ ). Ensuite, pour calculer la probabilité qu'une personne atteinte d'une maladie  $m_k$  présente un ensemble particulier de symptômes  $s'_1, \dots, s'_m$ , on calcule

$$P((s'_1, \dots, s'_m) \mid m_k) = \prod_{j=1}^m P(s'_j = s'_j \mid m_k)$$

Avec ce modèle, la classification fonctionne alors en utilisant une règle de décision à posteriori maximale. Étant donné un point de données  $\mathbf{x}$ , nous calculons la probabilité postérieure de son appartenance à chaque classe  $c_i$  et classons  $\mathbf{x}$  dans la classe ayant la probabilité postérieure la plus élevée. Plus précisément, nous calculons.

$$(3.12)$$

Notez que dans la dernière étape, puisque  $P(X = x)$  est une constante pour toutes les classes le problème se ramène alors à chercher des numérateurs. Comme nous le verrons plus tard, le fait de ne pas avoir cette étape de division rend un classificateur de Naïve Bayes plus facile à mettre en œuvre sur un schéma de chiffrement partiellement homomorphe.

### 3.4 Régression linéaire

La régression linéaire est l'un des algorithmes de machine learning les plus fondamentaux. Nous modélisons une variable cible ou de sortie comme une fonction linéaire de variables d'entrée (qui ont vraisemblablement une certaine relation avec la variable cible), plus un terme d'erreur normalement distribué, formellement

$$y = \langle \beta, \mathbf{x} \rangle + \epsilon \quad (3.13)$$

Par exemple, nous pouvons modéliser l'espérance de vie d'une personne comme une fonction linéaire de son revenu et de son état de santé, donc si nous avons un vecteur  $\mathbf{x} = (\text{revenu}, \text{état de santé})$  qui contient le revenu d'une personne et son état de santé, nous pouvons alors calculer l'estimation de l'espérance de vie de cette personne en utilisant

$$\text{esperancedevie} = \langle \beta, \mathbf{x} \rangle + \epsilon \quad (3.14)$$

Maintenant la question est de savoir quelle  $\beta$  choisir? Pour résoudre  $\beta$ , on calcule le  $\beta$  qui minimise l'erreur des moindres carrés, c'est-à-dire

$$\beta = \arg \min_{\beta} \left( \frac{1}{2} \sum (y_i - \langle \beta, \mathbf{x}_i \rangle)^2 \right)$$

Le  $\frac{1}{2}$  est pris par commodité lorsque nous prenons la dérivée. Si nous avons  $n$  caractéristiques et  $d$  points de données, alors  $X$  désigne la matrice de conception  $d \times n$  dont la  $i$ -ème ligne et la  $j$ -ème colonne contiennent la valeur de la  $j$ -ème caractéristique du  $i$ -ème point de données, la solution du problème d'optimisation ci-dessus est la suivante

$$\beta^* = (X^T X)^{-1} X^T y \quad (3.16)$$

### 3.5 Annalyse des composantes principales (ACP)

Un problème courant dans l'apprentissage automatique est la malédiction de la dimensionnalité. Il s'agit du phénomène selon lequel le volume d'un espace caractéristique augmente de manière exponentielle avec le nombre de dimensions.

---

## BIBLIOGRAPHY

- [1] RONALD CRAMER<sup>†</sup> and VICTOR SHOUP<sup>‡</sup>. “DESIGN AND ANALYSIS OF PRACTICAL PUBLIC-KEY ENCRYPTION SCHEMES SECURE AGAINST ADAPTIVE CHOSEN CIPHERTEXT ATTACK”. In: (). URL: <https://epubs.siam.org/doi/pdf/10.1137/S0097539702403773>.
- [2] Pedro Domingos and Michael Pazzani. “On the Optimality of the Simple Bayesian Classifier under Zero-One Loss”. In: (). URL: [http://engr.case.edu/ray\\_soumya/mlrg/optimality\\_of\\_nb.pdf](http://engr.case.edu/ray_soumya/mlrg/optimality_of_nb.pdf).
- [3] Craig Gentry. “Computing Arbitrary Functions of Encrypted Data”. In: (March 2010,). URL: <https://cacm.acm.org/magazines/2010/3/76272-computing-arbitrary-functions-of-encrypted-data/fulltext?mobile=false>.
- [4] Yehuda Lindell Jonathan Katz. Introduction to Modern Cryptography Principles and Protocols. Chapman and Hall CRC, 2007.
- [5] CHRISTOPHER M.BISHOP. “PATTERN RECOGNITION AND MACHINE LEARNING”. In: (). URL: <https://epubs.siam.org/doi/pdf/10.1137/S0097539702403773>.
- [6] Ron Rothblum. “Homomorphic Encryption: from Private-Key to Public-Key”. In: (). URL: <https://www.iacr.org/archive/tcc2011/65970216/65970216.pdf>.
- [7] Djiby SOW. "Introduction à la Sécurité Prouvée en Cryptographie à Clés publique. 2016. URL: [https://nitaj.users.lmno.cnrs.fr/cimpamaure/cours\\_securite-prouvee-crypto\\_Djiby\\_SOW-CIMPA.pdf](https://nitaj.users.lmno.cnrs.fr/cimpamaure/cours_securite-prouvee-crypto_Djiby_SOW-CIMPA.pdf).

- [8] Kai-Min Chung - Yael Kalai - Salil Vadhan<sup>‡</sup>. “Improved Delegation of Computation using Fully Homomorphic Encryption”. In: (April 28, 2010). URL: <https://people.seas.harvard.edu/~salil/research/delegation-eprint-apr10.pdf>.